

1. 개요 및 현황

가구 이미지 기반 상품 카테고리 분류 모델 개발 및 시각화

CNN 딥러닝 모델을 활용한 이미지 분류 프로젝트

작성자: 모하영 / 인공지능개발 양성과정 / 2026.06

목표

- 01 프로젝트 개요
- 02 과제 범위 및 추진 방법
- 03 데이터 수집 및 분석
- 04 데이터 전처리
- 05 CNN 모델 정의 및 학습
- 06 모델 평가 및 예측 결과
- 07 Streamlit 프로토타입
- 08 트러블 슈팅 및 개선방안
- 09 소감 및 후기

01

프로젝트 개요

1. 개요 및 현황

프로젝트 추진 배경 및 목적

이전 웹 프로젝트에서 키워드 검색의 한계를 경험하고, CNN 이미지 분류 모델로 해결 방향을 설계하였다.

문제 인식

키워드 검색은 가구의 형태·색상·구조 특성을 반영하기 어렵다.

해결 방향

CNN 모델로 이미지에서 직접 특징을 추출하여 카테고리를 분류한다.

구현 목표

침대·의자·소파·테이블·수납장 5개 카테고리를 이미지로 자동 분류한다.

2. 과제 범위

과제 범위

데이터 수집부터 Streamlit 프로토타입까지 6단계로 과제 범위를 정의하였다.

데이터 수집

CIFAR-100 활용

클래스 선정

bed, chair, couch, table, wardrobe

전처리

라벨 변환 및 픽셀 정규화

모델 학습

CNN 이미지 분류 모델

성능 평가

Accuracy · Loss · Confusion Matrix

프로토타입

Streamlit 업로드 및 예측 화면

3. 과제 추진 방법

구축 대상 선정 기준

데이터 접근성, 모델 구현 가능성, 서비스 확장성 3가지 기준으로 구축 대상을 선정하였다.

데이터 접근성

CIFAR-100 공개 데이터셋으로 이미지와 라벨을 바로 확보할 수 있다.

지도 학습 기반 이미지 분류에 적합

모델 구현 가능성

가구 이미지는 형태·색상 특징이 뚜렷해 CNN 모델 적용에 적합하다.

TensorFlow/Keras로 전처리와 학습 구현 가능

서비스 확장성

상품 등록, 이미지 검색, 추천 기능과 연계하여 확장할 수 있다.

쇼핑몰 서비스 기능으로 확장 가능

3. 과제 추진 방법

AI 예측 분석모델 적용 대상

가구 이미지의 시각적 특징을 CNN 모델로 학습하여 5개 카테고리를 자동 분류한다.

상품관리 기능

가구 이미지 기반 카테고리 자동 분류

수집 데이터

CIFAR-100 가구 관련 5개 클래스

예측 인자

색상·형태·윤곽·질감 등 시각적 특징


예측 대상

bed · chair · couch · table · wardrobe

3. 과제 추진 방법

AI 분석모델 구축 프로세스

데이터 수집부터 결과 시각화까지 5단계 흐름으로 모델을 구축하였다.



4. 주요 결과물

데이터 수집

CIFAR-100에서 가구 관련 5개 클래스를 추출하여 학습/테스트 데이터를 구성하였다.



전체 클래스




가구 클래스



학습 데이터



테스트 데이터



이미지 크기(RGB)

```
학습 이미지 : (50000, 32, 32, 3)
학습 라벨 : (50000, 1)
테스트 이미지 : (10000, 32, 32, 3)
테스트 라벨 : (10000, 1)
```

```
[5, 20, 25, 84, 94]
['bed', 'chair', 'couch', 'table', 'wardrobe']
```

- 클래스별 학습 500장, 테스트 100장으로 균등 구성
- 이미지 크기 32x32 RGB 배열 형태
- Keras API로 별도 다운로드 없이 불러오기 가능

4. 주요 결과물

데이터 분석

CIFAR-100 이미지 배열 구조와 클래스별 시각적 특징을 분석하였다.

이미지 데이터 특성

- 32×32 RGB 배열 (32, 32, 3) 형태로 제공된다.
- 각 클래스는 형태·색상·윤곽 등 시각적 특징으로 구분된다.
- 샘플 이미지와 클래스 구성 중심으로 분석하였다.



4. 주요 결과물

탐색적 데이터 분석 (EDA)

이미지 데이터 품질 및 라벨 확인

- CIFAR-100은 정제된 데이터셋으로 결측치 처리가 불필요하였다.
- 이미지 배열과 정답 라벨이 함께 제공된다.
- 가구 5개 클래스 필터링 후 라벨을 0~4로 변환하였다.

#가구 데이터 필터링

가구 학습 이미지: (2500, 32, 32, 3)

가구 학습 라벨: (2500,)

가구 테스트 이미지: (500, 32, 32, 3)


가구 테스트 라벨: (500,)

4. 주요 결과물

탐색적 데이터 분석 (EDA)

클래스별 데이터 분포

- 5개 클래스가 동일한 개수로 균등하게 구성되어 있다.
- 학습 데이터 클래스별 500장, 테스트 데이터 클래스별 100장이다.
- 클래스 불균형 문제는 크지 않다고 판단하였다.



4. 주요 결과물

데이터 전처리

클래스 필터링 → 라벨 변환 → 픽셀 정규화 3단계로 CNN 입력에 맞게 전처리하였다.

- CIFAR-100에서 가구 관련 5개 클래스만 필터링하였다.
- 기존 라벨 번호를 0~4 범위로 변환하였다.
- 픽셀값을 0~255에서 0~1 범위로 정규화하였다.
- 정규화로 CNN 모델이 안정적으로 학습할 수 있도록 하였다.

정규화 후 최소값: 0.0
정규화 후 최대값: 1.0

4. 주요 결과물

CNN 모델 정의 및 컴파일

Conv2D → MaxPooling2D → Flatten → Dense
구조로 모델을 정의하고 Adam으로 컴파일하였다.

모델 구조

- Conv2D: 윤곽·색상·형태 특징 추출
- MaxPooling2D: 중요 특징 압축
- Flatten → Dense: 최종 카테고리 분류

컴파일 설정

- Optimizer: Adam
- Loss: sparse_categorical_crossentropy
- Metric: accuracy

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 30, 30, 32)	896
max_pooling2d (MaxPooling2D)	(None, 15, 15, 32)	0
conv2d_1 (Conv2D)	(None, 13, 13, 64)	18,496
max_pooling2d_1 (MaxPooling2D)	(None, 6, 6, 64)	0
flatten (Flatten)	(None, 2304)	0
dense (Dense)	(None, 128)	295,040
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 5)	645

Total params: 315,077 (1.20 MB)

Trainable params: 315,077 (1.20 MB)

Non-trainable params: 0 (0.00 B)

```
model.compile(  
    optimizer="adam",  
    loss="sparse_categorical_crossentropy",  
    metrics=["accuracy"]  
)
```

4. 주요 결과물

CNN 모델 학습

전처리된 가구 이미지로 CNN 모델을 학습하고
검증 데이터로 성능 변화를 모니터링하였다.

- 전처리된 가구 이미지 데이터로 CNN 모델을 학습하였다.
- 학습 데이터 일부를 검증 데이터로 분리하여 성능 변화를 확인하였다.
- epoch는 전체 학습 데이터를 반복 학습하는 횟수를 의미한다.
- 학습 완료 모델은 Streamlit 시연을 위해 저장하였다.

```
Epoch 1/15
63/63 ————— 4s 22ms/step - accuracy: 0.3295 - loss: 1.5039 - val_accuracy: 0.4140 - val_loss: 1.3514
Epoch 2/15
63/63 ————— 1s 17ms/step - accuracy: 0.4645 - loss: 1.3054 - val_accuracy: 0.5540 - val_loss: 1.1299
Epoch 3/15
63/63 ————— 1s 17ms/step - accuracy: 0.5425 - loss: 1.1263 - val_accuracy: 0.5940 - val_loss: 1.0383
Epoch 4/15
63/63 ————— 1s 17ms/step - accuracy: 0.5820 - loss: 1.0405 - val_accuracy: 0.6280 - val_loss: 1.0079
Epoch 5/15
63/63 ————— 1s 16ms/step - accuracy: 0.6215 - loss: 0.9452 - val_accuracy: 0.6420 - val_loss: 0.9723
Epoch 6/15
63/63 ————— 1s 17ms/step - accuracy: 0.6605 - loss: 0.8722 - val_accuracy: 0.6540 - val_loss: 0.9147
Epoch 7/15
63/63 ————— 1s 19ms/step - accuracy: 0.6920 - loss: 0.8075 - val_accuracy: 0.6520 - val_loss: 0.9121
Epoch 8/15
63/63 ————— 1s 19ms/step - accuracy: 0.6905 - loss: 0.7811 - val_accuracy: 0.6620 - val_loss: 0.8865
Epoch 9/15
63/63 ————— 1s 19ms/step - accuracy: 0.7400 - loss: 0.6918 - val_accuracy: 0.6060 - val_loss: 1.0233
Epoch 10/15
63/63 ————— 2s 23ms/step - accuracy: 0.7395 - loss: 0.6840 - val_accuracy: 0.6620 - val_loss: 0.9065
Epoch 11/15
63/63 ————— 2s 24ms/step - accuracy: 0.7815 - loss: 0.5987 - val_accuracy: 0.6640 - val_loss: 0.8936
Epoch 12/15
63/63 ————— 2s 20ms/step - accuracy: 0.8060 - loss: 0.5360 - val_accuracy: 0.6480 - val_loss: 0.9155
Epoch 13/15
...
Epoch 14/15
63/63 ————— 1s 17ms/step - accuracy: 0.8505 - loss: 0.4438 - val_accuracy: 0.6720 - val_loss: 0.9104
Epoch 15/15
63/63 ————— 1s 20ms/step - accuracy: 0.8525 - loss: 0.3983 - val_accuracy: 0.6520 - val_loss: 1.0082
```

4. 주요 결과물

Accuracy 및 Loss 변화 시각화


학습/검증 데이터의 정확도와 손실값 변화를 그래프로 확인하였다.

Accuracy

모델이 이미지를 올바른 클래스로 분류한 비율이다.

Loss


예측값과 실제값의 차이이며, 낮을수록 오차가 작다.



4. 주요 결과물

테스트 데이터 기반 성능 평가

5개 클래스별 예측 확률을 계산하고 가장 높은 확률의 클래스를 최종 예측값으로 선택한다.



테스트 기준

클래스별 Precision, Recall, F1-score로 각 가구 클래스의 예측 성능을 비교하였다.

	precision	recall	f1-score	support
bed	0.5538461	0.36	0.436363636	100
chair	0.8734177	0.69	0.770949721	100
couch	0.4765625	0.61	0.535087719	100
table	0.5754716	0.61	0.59223301	100
wardrobe	0.7295081	0.89	0.801801802	100
accuracy	0.632	0.632	0.632	0.632
macro avg	0.6417612	0.632	0.627287178	500
weighted a	0.6417612	0.632	0.627287178	500


4. 주요 결과물

실제 라벨과 예측 라벨 비교

혼동 행렬(Confusion Matrix)로 클래스별 예측 정확도를 시각적으로 확인하였다.

대각선 값이 높을수록 해당 클래스를 잘 예측한 것이며, chair와 wardrobe는 상대적으로 잘 분류되었다.

bed와 couch는 형태가 유사하여 32×32 저해상도에서 혼동되는 경우가 있었다.



4. 주요 결과물 — 프로토타이핑

Streamlit 기반 이미지 업로드 화면

저장된 CNN 모델을 불러와 사용자가 이미지를 업로드하고 카테고리를 예측하는 화면을 구성하였다.

- 저장된 CNN 모델을 불러와 재학습 없이 예측만 수행한다.
- 업로드 이미지를 32x32 RGB로 변환하여 모델에 입력한다.
- 사용자가 직접 이미지를 업로드하여 예측을 수행할 수 있다.

가구 이미지 기반 카테고리 분류

CIFAR-100 가구 클래스 기반 CNN 딥러닝 개인 프로젝트

[프로젝트 설명](#) [예측 시연](#) [학습 결과](#) [프로젝트 정보](#)

프로젝트 설명

본 프로젝트는 CIFAR-100 데이터셋에서 가구 관련 5개 클래스를 추출하여 CNN 모델을 학습하고, 업로드된 가구 이미지의 카테고리를 예측하는 딥러닝 프로젝트입니다.

분류 클래스	학습 이미지	테스트 이미지
5개	2,500장	500장

- 예측 대상: 침대, 의자, 소파, 테이블, 수납장
- 사용 모델: CNN 이미지 분류 모델
- 이미지 크기: 32 x 32 RGB
- 저장 모델: `models/furniture_cnn.keras`


본 모델은 CIFAR-100의 32 x 32 저해상도 이미지로 학습했기 때문에 실제 고해상도 상품 이미지에서는 오분류가 발생할 수 있습니다.

- <https://dlmohayoungfurnitureproject-witnf7mij24cedlvutysmn.streamlit.app/>

4. 주요 결과물 - 프로토타이핑 가구 카테고리 예측 결과

업로드된 이미지에 대해 예측 카테고리, 확률, Top-3 후보를 화면에 출력하였다.

- 예측 카테고리, 예측 확률을 화면에 출력하였다.
- 클래스별 예측 확률 그래프로 모델 판단 근거를 시각화하였다.
- Top-3 예측 후보를 함께 제공하여 결과를 비교할 수 있도록 하였다.



업로드 이미지

모델 입력을 위해 이미지는 내부적으로 32 x 32 크기로 변환됩니다.

> 모델이 실제로 보는 32 x 32 이미지

현재 이미지 기준 예측 결과


침대 (bed)

모델이 이 이미지를 침대 카테고리로 분류했습니다.

예측 확률: 41.85%

Top-3 예측 후보

카테고리	영문 라벨	예측 확률(%)
침대	bed	41.85
소파	couch	32.49
테이블	table	21.67



5. 트러블 슈팅

트러블 슈팅

개발 과정에서 발생한 3가지 주요 문제와 해결 방법을 정리하였다.

문제 1. Jupyter Notebook TensorFlow 모듈 인식 오류

원인: 터미널 가상환경과 Jupyter 커널의 Python 환경이 달랐다.

해결: Jupyter 커널을 .venv Python 환경으로 변경하였다.

문제 2. Streamlit 실행 시 TensorFlow 없음 오류

원인: 가상환경이 활성화되지 않은 상태에서 앱을 실행하였다.

해결: .venv 활성화 후 streamlit run 명령어를 실행하였다.

문제 3. 학습 시간 과다 소요

원인: CNN 이미지 학습은 CPU 환경에서 시간이 오래 걸린다.

해결: 향후 Colab 또는 Kaggle GPU 환경 활용을 권장한다.

6. 보완사항 및 개선점

보완사항 및 개선점

데이터 품질, 모델 성능, 서비스 확장 3가지 축에서 개선 방향을 도출하였다.

데이터 품질 개선

- CIFAR-100은 32×32 저해상도로 실제 쇼핑물 이미지와 차이가 있다.
- 고해상도 가구 상품 이미지 수집이 필요하다.

모델 성능 개선

- 기본 CNN 구조는 복잡한 이미지 분류에 한계가 있다.
- MobileNet, EfficientNet 등 전이학습 모델 적용으로 성능 향상 가능하다.

서비스 기능 확장

- 예측 결과를 상품 등록 기능과 연계하면 카테고리 자동 추천으로 확장 가능하다.
- 이미지 기반 검색·추천 기능과 연결하면 쇼핑물 탐색 경험을 개선할 수 있다.

7. 소감 및 후기

소감 및 후기

CNN 기반 이미지 분류 모델의 전체 구현 과정을 직접 경험하였다.

- 이미지 데이터는 픽셀값과 라벨을 기반으로 학습된다는 점을 이해할 수 있었다.
- CNN 모델로 형태·색상·윤곽 특징을 추출하여 가구 카테고리를 분류하는 과정을 경험하였다.
- CIFAR-100의 32×32 저해상도 이미지로 인해 실제 쇼펍몰 이미지와 차이가 있었다.

향후 실제 가구 이미지와 데이터 증강·전이학습을 적용하여 모델 성능을 개선하고 싶다.