

2026년도 인공지능 심화과정

AI 머신러닝 개인 프로젝트

과제명	포르투갈 학생 생활패턴 기반 최종 성적 예측 및 학업 위험군 분류
담당자	모하영

2026년 6 월 24 일

AI개발 수행내용

1. 사업과제 : 포르투갈 학생 생활패턴 기반 최종 성적 예측 및 학업 위험군 분류

2. 개요 및 현황

2.1 추진배경 및 목적

- 학생의 학업 성취도는 공부시간, 결석일수, 외출빈도, 건강상태, 가족관계, 과거 성적 등 다양한 생활패턴 및 학교생활 요인의 영향을 받을 수 있음
- 최종 성적이 나온 이후에는 학업 위험군에 대한 사전 대응이 어렵기 때문에, 학생 데이터를 활용하여 학업 위험 가능성을 조기 파악할 필요성이 있음
- 학생 성적 데이터를 분석하고 머신러닝 모델을 학습함으로써, 최종 성적에 영향을 줄 수 있는 주요 요인을 확인하고 성적 예측 가능성을 검토하고자 함
- 생활패턴 정보만 활용한 모델과 과거 성적 정보를 함께 활용한 모델을 비교하여, 입력 변수 구성에 따른 예측 성능 차이를 확인하고 학업 위험군 분류 모델을 구축하고자 함

2.2 과제 범위

과제구분		내용
AI	AI기반 학생 성적 예측 모델 구현	학생 성적 예측모델 구현
		Student Performance Dataset 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA 도구 활용)
		회귀 및 분류 예측모델 선정 및 학습
		MAE, RMSE, R2, Accuracy, F1-score 등 평가지표를 활용한 모델 성능 평가
		입력값 기반 최종 성적 및 학업 위험군 예측 시스템 구현
		테스트
시각화	학생 생활패턴 및 성적 데이터 분석 결과 시각화	학생 생활패턴 및 성적 데이터 분석 결과 시각화
		최종 성적 분포, 공부시간, 결석일수, 과거 성적 관계 시각화
		모델 A/B 성능 비교표 시각화
		테스트
		Streamlit 화면 기반 예측 결과 확인 및 시연

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

- Student Performance Dataset은 공개 데이터로 제공되어 수집 및 활용이 용이함
- 학생의 학교생활, 가정환경, 생활패턴, 결석일수, 과거 성적 등 다양한 독립변수를 포함하고 있음
- 최종 성적 G3가 예측 대상 변수로 제공되어 회귀 및 분류 모델 학습에 적합함

○ 예측모델 개발 효율성

- 데이터가 표 형태로 정리되어 있어 전처리, 인코딩, 모델 학습 과정을 비교적 명확하게 수행할 수 있음
- 회귀 모델과 분류 모델을 모두 적용할 수 있어 수업에서 학습한 머신러닝 개념을 함께 활용할 수 있음
- 생활패턴 기반 모델 A와 과거 성적을 포함한 모델 B를 비교하여 입력변수 구성에 따른 성능 차이를 확인할 수 있음


○ 학업 위험군 조기 식별 가능성

- 최종 성적을 기준으로 위험/보통/우수 그룹을 생성하여 학업 위험군을 분류할 수 있음
- 결석일수, 공부시간, 건강상태, 외출빈도 등 생활패턴 변수를 활용하여 성적과의 관계를 분석할 수 있음
- 예측 결과를 streamlit 화면으로 구현하여 사용자가 입력값에 따른 예측 결과를 직접 확인할 수 있음

2) AI 예측 분석모델 적용 대상

학업관리 기능	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
학생 최종 성적 예측 및 학업 위험군 분류	- Student Perfirmaxce Dataset(Student-por.csv) - 포르투갈 중등학생의 학교생활, 가정환경, 생활패턴, 결석일수, 과거성적, 최종 성적 데이터 - 전체 데이터 크기: 649행, 33개 컬럼	- 학교생활 변수: school, studytime, failures, absences, schoolsup, activities - 가정환경 변수: famsize, Pstatus, Medu, Fedu, famrel - 생활패턴 변수: freetime, goout, Dalc, Walc, health, internet - 과거 성적 변수: G1, G2 - 모델 A: G1, G2 제외 - 모델 B: G1, G2 포함	- 회귀 분석: 최종 성적 G3 점수 예측 - 분류 분석: G3 점수 기준 위험/보통/우수 그룹 예측 - 위험: 0~9점, 보통: 10~14점, 우수: 15~20점

3) AI 분석모델 구축 프로세스



연구개발 주요 결과물

1. 데이터 수집


- 본 프로젝트에서는 Student Performance Dataset의 `student-por.csv` 파일을 활용하였다.
- 해당 데이터는 포르투갈 중등학생의 학교생활, 가정환경, 생활패턴, 결석일수, 과거 성적, 최종 성적 정보를 포함한다.
- 전체 데이터는 649행, 33개 컬럼으로 구성되어 있으며, 최종 성적 G3를 예측 대상으로 사용하였다.
- 데이터에는 학생 이름과 같은 직접적인 개인식별정보는 포함되어 있지 않으나, 성별, 가정환경, 생활습관 등 민감할 수 있는 변수가 포함되어 있어 실제 활용 시 윤리적 검토가 필요하다.

	school	sex	age	address	famsize	Pstatus	Medu	Fedu	Mjob	Fjob	...	famrel	freetime	goout	Dalc	Walc	health	absences	G1	G2	G3
0	GP	F	18	U	GT3	A	4	4	at_home	teacher	...	4	3	4	1	1	3	4	0	11	11
1	GP	F	17	U	GT3	T	1	1	at_home	other	...	5	3	3	1	1	3	2	9	11	11
2	GP	F	15	U	LE3	T	1	1	at_home	other	...	4	3	2	2	3	3	6	12	13	12
3	GP	F	15	U	GT3	T	4	2	health	services	...	3	2	2	1	1	5	0	14	14	14
4	GP	F	16	U	GT3	T	3	3	other	other	...	4	3	2	1	2	5	0	11	13	13

5 rows × 33 columns

2. 데이터 분석

2.1 학생 성적 데이터 상관관계(Heatmap)



- 학생 성적 예측을 위해 숫자형 변수 간 상관관계를 분석하였다.
- 분석 결과 G1, G2는 최종 성적 G3와 높은 상관관계를 보였으며, 특히 G2와 G3의 상관관계가 가장 높게 나타났다.
- studytime은 G3와 약한 양의 관계를 보였고, failures는 G3와 음의 관계를 보였다.
- absences는 G3와 약한 음의 관계를 보였으나, 단일 변수만으로 최종 성적을 설명하기에는 한계가 있었다.
 - 성적 변수: G1(1차 성적), G2(2차 성적), G3(최종 성적)
 - 학교생활 변수: studytime(주간 공부시간), failures(과거 낙제 횟수), absences(결석일수)
 - 생활패턴 변수: freetime(자유시간), goout(외출 빈도), health(건강상태)
 - 가정환경 변수: Medu(어머니 교육수준), Fedu(아버지 교육수준), famrel(가족관계)


2.2 탐색적 데이터 분석


- 결측치 및 중복값 통계
 - 데이터 확인 결과 전체 결측치 수는 0개로 나타났다.
 - 중복 데이터 확인 결과 중복 행은 0개로 나타났다.
 - 별도의 결측치 대체나 중복 행 제거 과정 없이 데이터 전처리를 진행하였다.

school	0	reason	0	higher	0
sex	0	guardian	0	internet	0
age	0	traveltime	0	romantic	0
address	0	studytime	0	famrel	0
famsize	0	failures	0	freetime	0
Pstatus	0	schoolsup	0	...	
Medu	0	famsup	0	absences	0
Fedu	0	paid	0	G1	0
Mjob	0	activities	0	G2	0
Fjob	0	nursery	0	G3	0
				dtype: int64	

np.int64(0)

- 주요 변수별 데이터 분포(Histogram)
 - 최종 성적 G3는 0점부터 19점까지 분포하였다.
 - G3 평균은 약 11.91점으로 나타났다.
 - G3 기준 학업 수준은 보통 그룹이 가장 많았다.
 - 학업 수준 그룹 분포는 위험 100명, 보통 418명, 우수 131명으로 확인되었다.





○ 데이터 전처리

- 결측치와 중복값을 확인한 뒤, 머신러닝 학습을 위해 데이터를 정리하였다.
- 회귀 모델의 Target은 G3로 설정하고, 분류 모델의 Target은 G3 기준 위험/보통/우수 그룹으로 생성하였다.
- 문자형 변수는 인코딩을 통해 숫자형 변수로 변환하고, 학습 데이터와 테스트 데이터를 분리하였다.
- 아래 표는 전처리 과정을 거친 뒤 모델 학습에 사용한 데이터의 일부를 확인한 결과이다.

	school	sex	age	address	famsize	Pstatus	Medu	Fedu	Mjob	Fjob	...	famrel	freetime	goout	Dalc	Walc	health	absences	G1	G2	G3
644	MS	F	19	R	GT3	T	2	3	services	other	...	5	4	2	1	2	5	4	10	11	10
645	MS	F	18	U	LE3	T	3	1	teacher	services	...	4	3	4	1	1	1	4	15	15	16
646	MS	F	18	U	GT3	T	1	1	other	other	...	1	1	1	1	1	5	6	11	12	9
647	MS	M	17	U	LE3	T	3	1	services	services	...	2	4	5	3	4	2	6	10	10	10
648	MS	M	18	R	LE3	T	3	2	services	other	...	4	4	1	3	4	5	4	10	11	11

5 rows × 33 columns

3. 데이터 학습 및 모델정의

3.1 모델정의 및 학습

○ 회귀 모델 정의

- 최종 성적 G3 점수를 직접 예측하기 위해 선형 회귀(Linear Regression)와 KNN 회귀 모델을 사용하였다.

○ 분류 모델 정의

- 학생을 위험/보통/우수 그룹으로 분류하기 위해 로지스틱 회귀(Logistic Regression), KNN 분류, SVM 모델을 사용하였다.

○ 회귀 모델 학습 및 결과 정리

- 선형 회귀와 KNN 회귀 모델을 학습한 뒤, MAE, MSE, RMSE, R2 지표를 활용하여 성능 결과표를 생성하였다.

```
regression_result = pd.DataFrame({
    "Model": ["LinearRegression_A", "LinearRegression_B"],
    "MAE": [lr_A_result[0], lr_B_result[0]],
    "MSE": [lr_A_result[1], lr_B_result[1]],
    "RMSE": [lr_A_result[2], lr_B_result[2]],
    "R2": [lr_A_result[3], lr_B_result[3]]
})

regression_result
knn_result = pd.DataFrame({
    "Model": ["KNNRegression_A", "KNNRegression_B"],
    "MAE": [knn_A_result[0], knn_B_result[0]],
    "MSE": [knn_A_result[1], knn_B_result[1]],
    "RMSE": [knn_A_result[2], knn_B_result[2]],
    "R2": [knn_A_result[3], knn_B_result[3]]
})

regression_result_all = pd.concat([regression_result, knn_result], ignore_index=True)
regression_result_all
```

○ 분류 모델 학습 및 결과 정리

- 로지스틱 회귀, KNN 분류, SVM 모델을 학습한 뒤, 정확도(Accuracy),정밀도(Precision),재현율(Recall), F1-score 지표를 활용하여 성능 결과표를 생성하였다.

```
from sklearn.linear_model import LogisticRegression

log_A = LogisticRegression(max_iter=1000)
log_A.fit(X_A_train_c_scaled, y_clf_train)
log_pred_A = log_A.predict(X_A_test_c_scaled)

log_B = LogisticRegression(max_iter=1000)
log_B.fit(X_B_train_c_scaled, y_clf_train_B)
log_pred_B = log_B.predict(X_B_test_c_scaled)

from sklearn.svm import SVC

svm_A = SVC()
svm_A.fit(X_A_train_c_scaled, y_clf_train)
svm_pred_A = svm_A.predict(X_A_test_c_scaled)

svm_B = SVC()
svm_B.fit(X_B_train_c_scaled, y_clf_train_B)
svm_pred_B = svm_B.predict(X_B_test_c_scaled)

svm_A_result = classification_metrics(y_clf_test, svm_pred_A)
svm_B_result = classification_metrics(y_clf_test_B, svm_pred_B)

svm_classification_result = pd.DataFrame({
    "Model": ["SVM_A", "SVM_B"],
    "Accuracy": [svm_A_result[0], svm_B_result[0]],
    "Precision": [svm_A_result[1], svm_B_result[1]],
    "Recall": [svm_A_result[2], svm_B_result[2]],
    "F1": [svm_A_result[3], svm_B_result[3]]
})

classification_result_all = classification_result_all.drop_duplicates()
classification_result_all.to_csv("outputs/classification_result.csv", index=False,
encoding="utf-8-sig")
classification_result_all
```


3.2 모델학습 및 성능 비교

○ 회귀 모델 성능 평가

- 회귀 모델은 실제 G3 점수와 예측 G3 점수의 차이를 기준으로 성능을 평가하였다.
- MAE와 RMSE는 낮을수록 좋고, R2는 1에 가까울수록 모델 설명력이 높다.
- 회귀 모델에서는 LinearRegression_B 모델이 MAE:0.765, RMSE:1.215, R2:0.849로 가장 우수한 성능을 보였다.

○ 분류 모델 성능 평가

- 분류 모델은 실제 학업 수준 그룹과 예측 학업 수준 그룹이 얼마나 일치하는지를 기준으로 평가하였다.
- 분류 모델에서는 LogisticRegression_B 모델이 정확도(Accuracy):0.869, F1-score:0.869로 가장 높은 성능을 보였다.

○ 모델 A/B 비교

- 모델 B가 모델 A보다 전반적으로 높은 성능을 보였다.
- 이는 G1, G2 과거 성적 정보가 최종 성적 예측과 학업 수준 분류에 중요한 변수로 작용한다는 것을 의미한다.

```
KNN Regression Model A: (2.275384615384616, 9.066153846153846, np.float64(3.011005454354715), 0.07030169170651202)
KNN Regression Model B: (1.5569230769230769, 4.646769230769231, np.float64(2.1556366184422715), 0.5234921482488288)
```

	Model	Accuracy	Precision	Recall	F1
0	LogisticRegression_A	0.669231	0.643905	0.669231	0.636895
1	LogisticRegression_B	0.869231	0.869617	0.869231	0.869091
2	KNNClassifier_A	0.584615	0.560769	0.584615	0.545359
3	KNNClassifier_B	0.715385	0.740321	0.715385	0.686088

3.3 모델 예측

○ 학업 위험군 예측 결과

- G3 점수를 기준으로 학생을 위험, 보통, 우수 그룹으로 분류하였다.
- 위험 그룹은 0~9점, 보통 그룹은 10~14점, 우수 그룹은 15~20점으로 설정하였다.
- 분류 모델 중 LogisticRegression_B가 가장 높은 분류 성능을 보였다.
- 이를 통해 생활패턴 정보와 과거 성적 정보를 함께 활용하면 학생의 학업 수준을 비교적 정확하게 예측할 수 있음을 확인하였다.

grade_group		Model	Accuracy	Precision	Recall	F1
보통	418	0 LogisticRegression_A	0.669231	0.643905	0.669231	0.636895
우수	131	1 LogisticRegression_B	0.869231	0.869617	0.869231	0.869091
위험	100	2 KNNClassifier_A	0.584615	0.560769	0.584615	0.545359
Name: count, dtype: int64		3 KNNClassifier_B	0.715385	0.740321	0.715385	0.686088

4. 프로토타이핑(화면)

4.1 모델 예측

○ Streamlit 기반 학생 성적 예측 화면

- 사용자가 나이, 공부시간, 결석일수, 건강상태, 가족관계, 자유시간, 외출빈도, G1, G2 등의 정보를 입력하면 최종 성적 G3와 학업 수준 그룹을 예측하도록 구현하였다.
- 입력값은 포르투갈 중등학생 Student Performance Dataset 기준으로 구성하였으며, G1, G2, G3 성적은 0~20점 척도를 사용하였다.

포르투갈 학생 생활패턴 기반 성적 예측

Student Performance Dataset 기반 머신러닝 개인 프로젝트

프로젝트 설명

포르투갈 중등학생의 생활패턴, 결석 정보와 과거 성적을 활용해 최종 성적 G3와 학업 수준을 예측합니다.

학생 수 평균 G3 최다 그룹

649명 11.91점 보통

입력값 요약

나이 수정 17세	공부시간 수정 2단계	낙제 수정 0회
결석 수정 2일	건강 수정 4단계	가족 수정 4단계
자유 수정 3단계	외출 수정 3단계	인터넷 수정 yes
진학 수정 yes	G1 수정 11점	G2 수정 11점

예측 결과 모델 비교 데이터 정보

현재 입력값 기준 예측 결과

최종 성적 G3 11.6점 / 20점

보통 그룹

현재 입력값에서는 보통 그룹으로 분류됩니다. 생활패턴과 과거 성적 변화에 따라 결과가 달라질 수 있습니다.

예측 G3 학업 수준 사용 모델

11.6 보통 Model B

↓ -0.3 vs 평균

한 줄 해석: 현재 조건에서는 G3가 11.6점으로 예측되며, 학업 수준은 보통 그룹입니다.

모델 성능 요약

회귀 최고 모델

LinearRegression_B

RMSE 1.215 / R2 0.849

분류 최고 모델

LogisticRegression_B

Accuracy 0.869 / F1 0.869

입력값 수정

G2 2차 성적 (0-20점)

14점

반영

현재 입력값에서는 보통 그룹으로 분류됩니다. 생활패턴과 과거 성적 변화에 따라 결과가 달라질 수 있습니다.

예측 G3 학업 수준 사용 모델

12.2 보통 Model B

↑ +0.3 vs 평균

한 줄 해석: 현재 조건에서는 G3가 12.2점으로 예측되며, 학업 수준은 보통 그룹입니다.

모델 성능 요약

회귀 최고 모델

LinearRegression_B

RMSE 1.215 / R2 0.849

분류 최고 모델

LogisticRegression_B

Accuracy 0.869 / F1 0.869

○ 최종 성적 및 학업 위험군 예측 결과

- 예시 입력값을 기준으로 최종 성적 G3는 12.4점/20점으로 예측되었다.
- 예측된 학업 수준은 보통 그룹으로 나타났다.
- 모델 성능 비교 결과, 회귀에서는 LinearRegression_B, 분류에서는 LogisticRegression_B가 가장 우수한 성능을 보였다.

포르투갈 학생 생활패턴 기반 성적 예측

Student Performance Dataset 기반 머신러닝 개인 프로젝트

프로젝트 설명

포르투갈 중등학생의 생활패턴, 결석 정보와 과거 성적을 활용해 최종 성적 G3와 학업 수준을 예측합니다.

학생 수

평균 G3

최다 그룹

649명

11.91점

보통

입력값 요약

나이

수정

21세

공부시간

수정

2단계

낙제

수정

0회

결석

수정

2일

건강

수정

4단계

가족

수정

4단계

자유

수정

3단계

외출

수정

3단계

인터넷

수정

yes

진학

수정

yes

G1

수정

15점

G2

수정

11점

예측 결과 모델 비교 데이터 정보

현재 입력값 기준 예측 결과

최종 성적 G3 12.2점 / 20점

보통 그룹

현재 입력값에서는 보통 그룹으로 분류됩니다. 생활패턴과 과거 성적 변화에 따라 결과가 달라질 수 있습니다.

예측 G3

12.2

↑ +0.3 vs 평균

학업 수준

보통

사용 모델

Model B

한 줄 해석: 현재 조건에서는 G3가 12.2점으로 예측되며, 학업 수준은 보통 그룹입니다.

모델 성능 요약

회귀 최고 모델

LinearRegression_B

RMSE 1.215 / R2 0.849

분류 최고 모델

LogisticRegression_B

Accuracy 0.869 / F1 0.869

URL: <https://mlmohayoungproject-r5h2hvp8cyxa3akkytnfup.streamlit.app/>